Московский Государственный Технический Университет им. Н.Э. Баумана

СИСТЕМЫ ОБРАБОТКИ БОЛЬШИХ ДАННЫХ

Разработка приложений

к.т.н.
Папулин Сергей Юрьевич
papulin_bmstu@mail.ru

Москва, 2016/18

Лекция 8. Spark Streaming

Основные темы

- Особенности Spark Streaming
- Операции
- Архитектура

Существующие системы

TRIDENT

samza

Streaming Model	Native	Micro-batching	Micro-batching	Native	Native
API	Compositional		Declarative	Compositional	Declarative
Guarantees	At-least-once	Exactly-once	Exactly-once	At-least-once	Exactly-once
Fault Tolerance	Record ACKs		RDD based Checkpointing	Log-based	Checkpointing
State Management	Not build-in	Dedicated Operators	Dedicated DStream	Stateful Operators	Stateful Operators
Latency	Very Low	Medium	Medium	Low	Low
Throughput	Low	Medium	High	High	High
Maturity	High		High	Medium	Low

Spark Streaming

Словарь Spark Streaming

- Driver
- Executor
- Task
- Receiver
- RDD
- DStream
- Block
- Partition
- Transformation
- Window
- Output operation

Spark Streaming

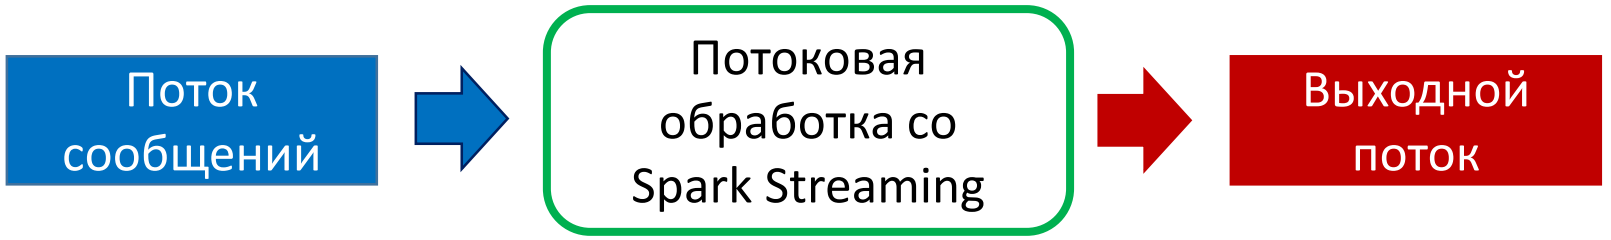

- Kafka
- Flume
- HDFS/S3
- Kinesis
- Twitter

- HDFS
- СУБД
- Dashboards

Spark Streaming. DStream

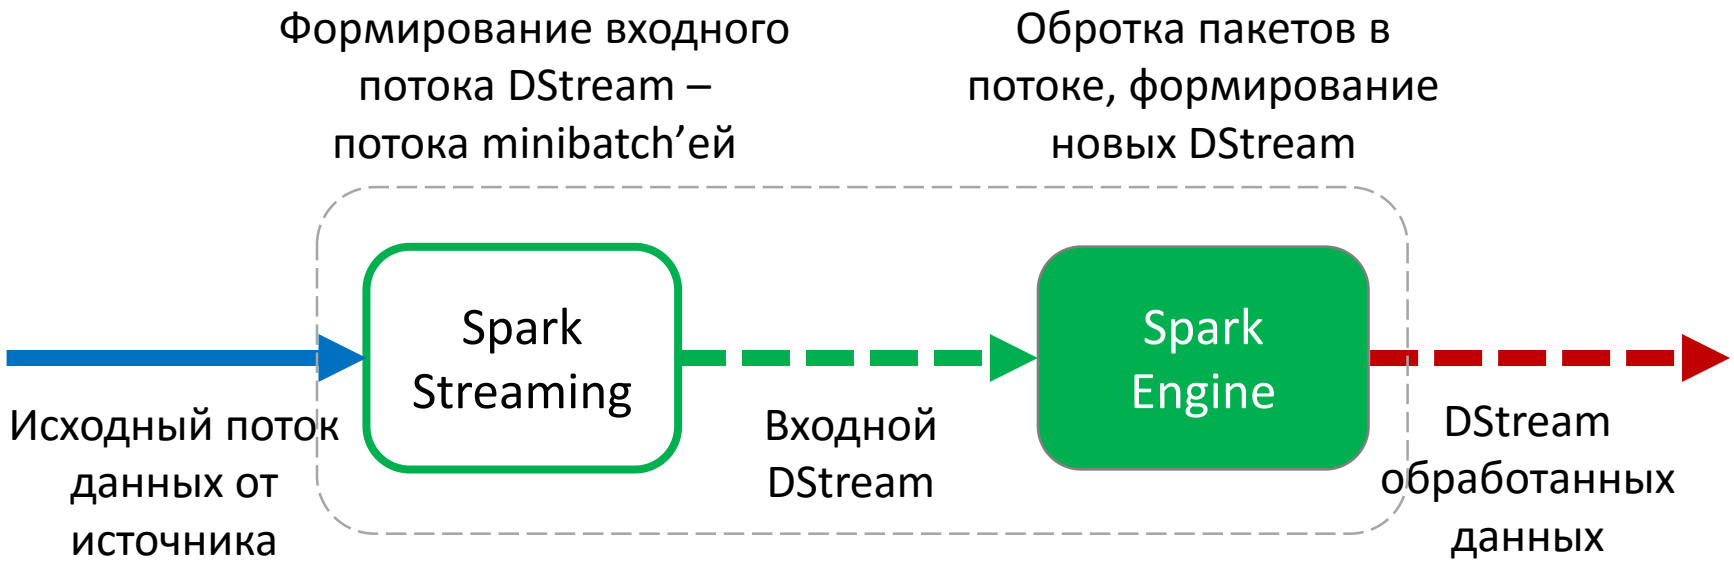

Spark Streaming. Dstream, RDD, операции

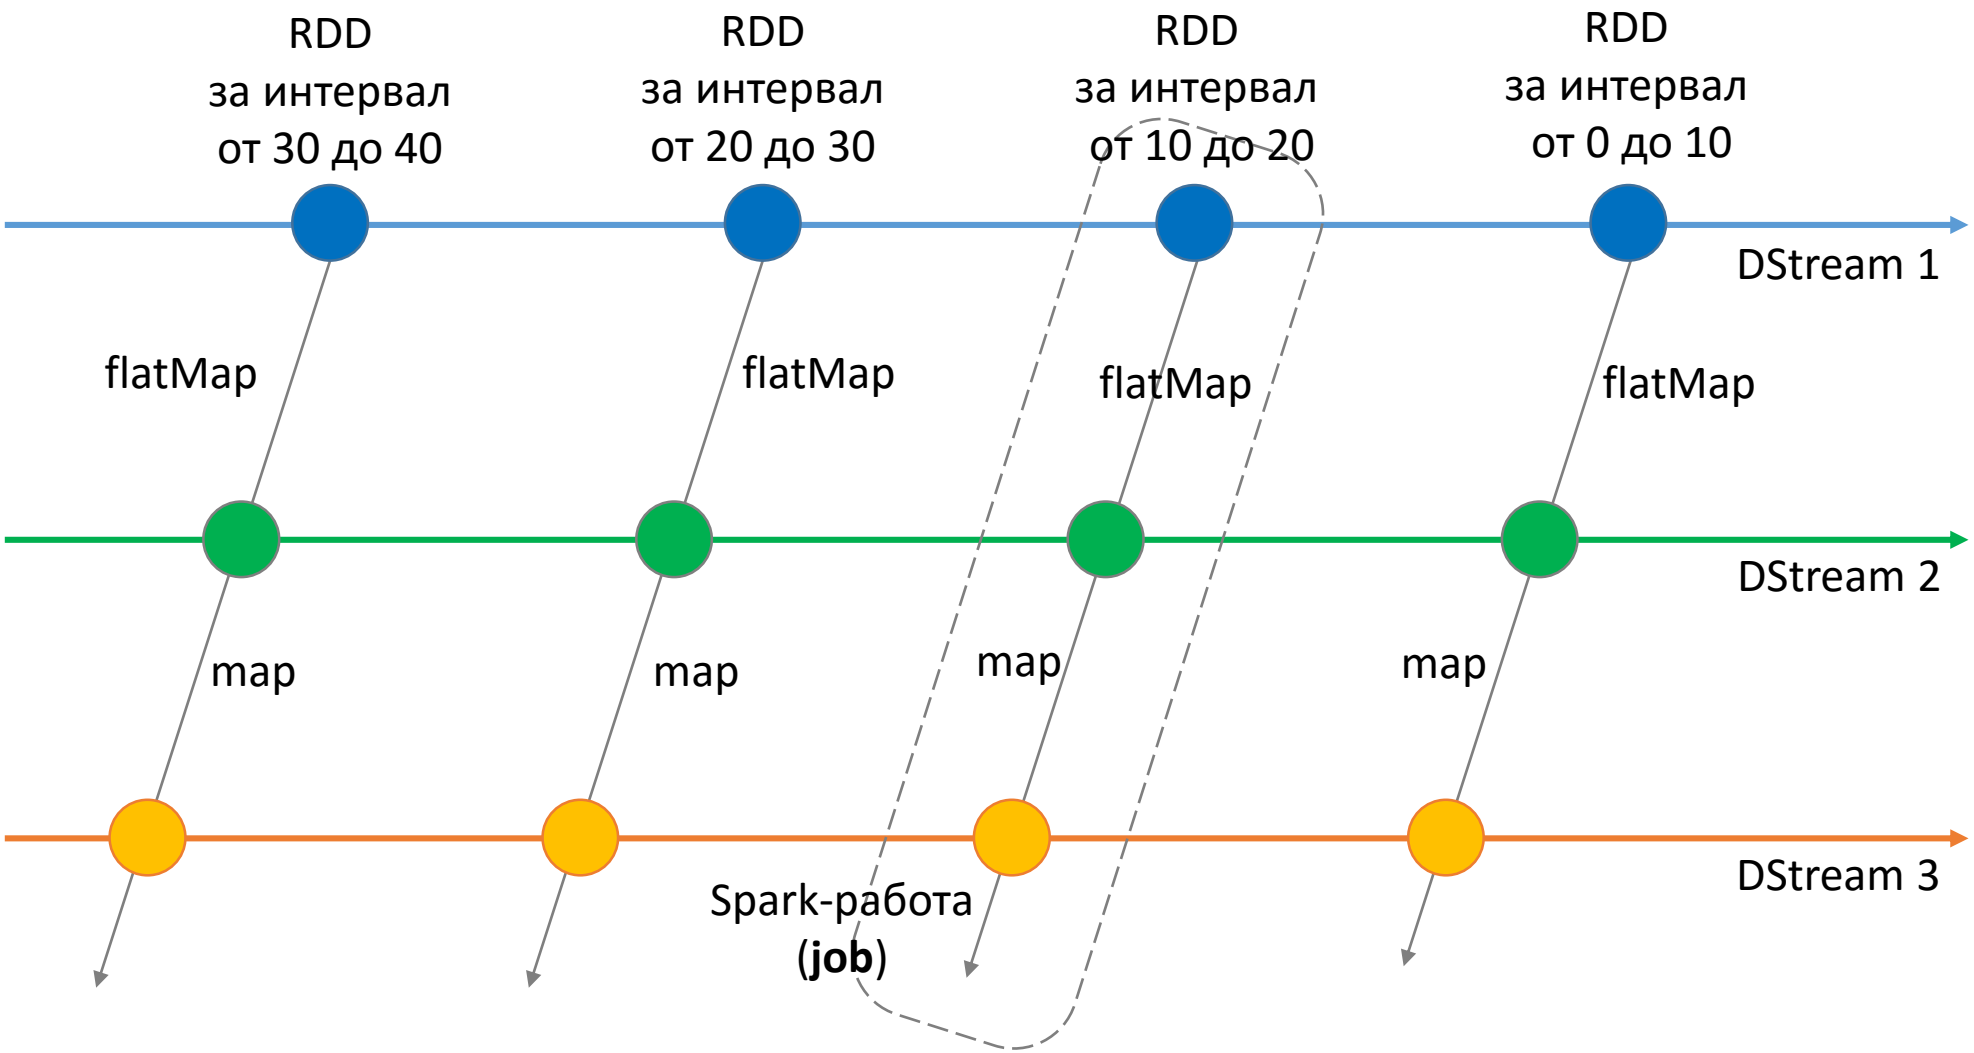

Операции

- Трансформации

  map, *filter* и др.

- Операции вывода (output operations) – действия

  print, *saveAsTextFiles* и др.

Типы трансформаций

- **Stateless**

  Обработка пакета (batch) не зависит от предыдущего пакета

- **Stateful**

  Для получения результата обработки текущего пакета используются результаты обработки предыдущих пакетов

Трансформации

map(func)

flatMap(func)

filter(func)

repartition(numPartitions)

union(otherStream)

count()

reduce(func)

countByValue()

reduceByKey(func, [numTasks])

join(otherStream, [numTasks])

cogroup(otherStream, [numTasks])

transform(func)

updateStateByKey(func)

Трансформации. Transform

Преобразование RDD в RDD для каждого RDD потока DStream

```
dstream2 = dstream1.transform(
    lambda rdd: rdd.sortBy(lambda x: x[1], ascending=False))
```

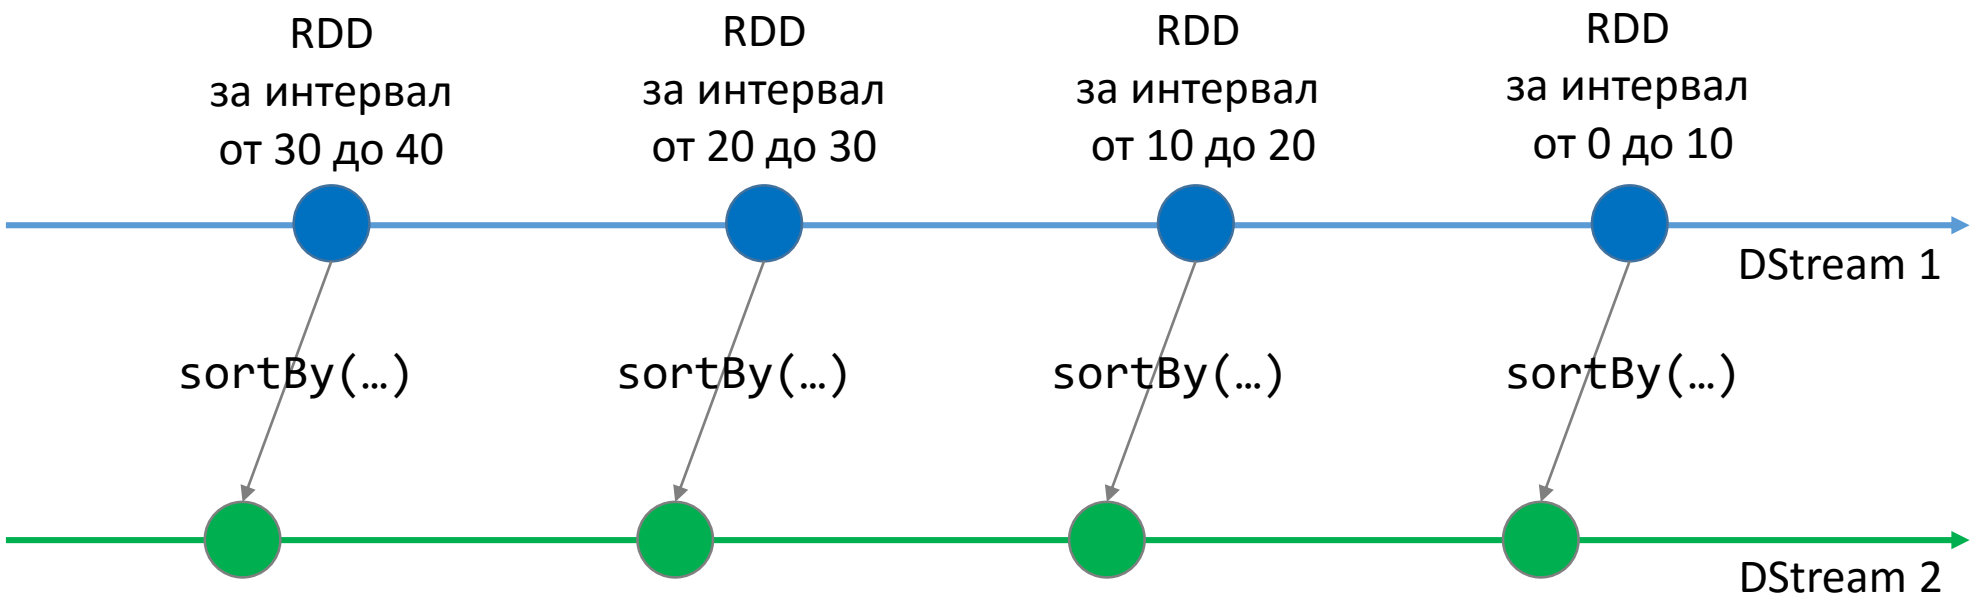

Окна в Spark Streaming

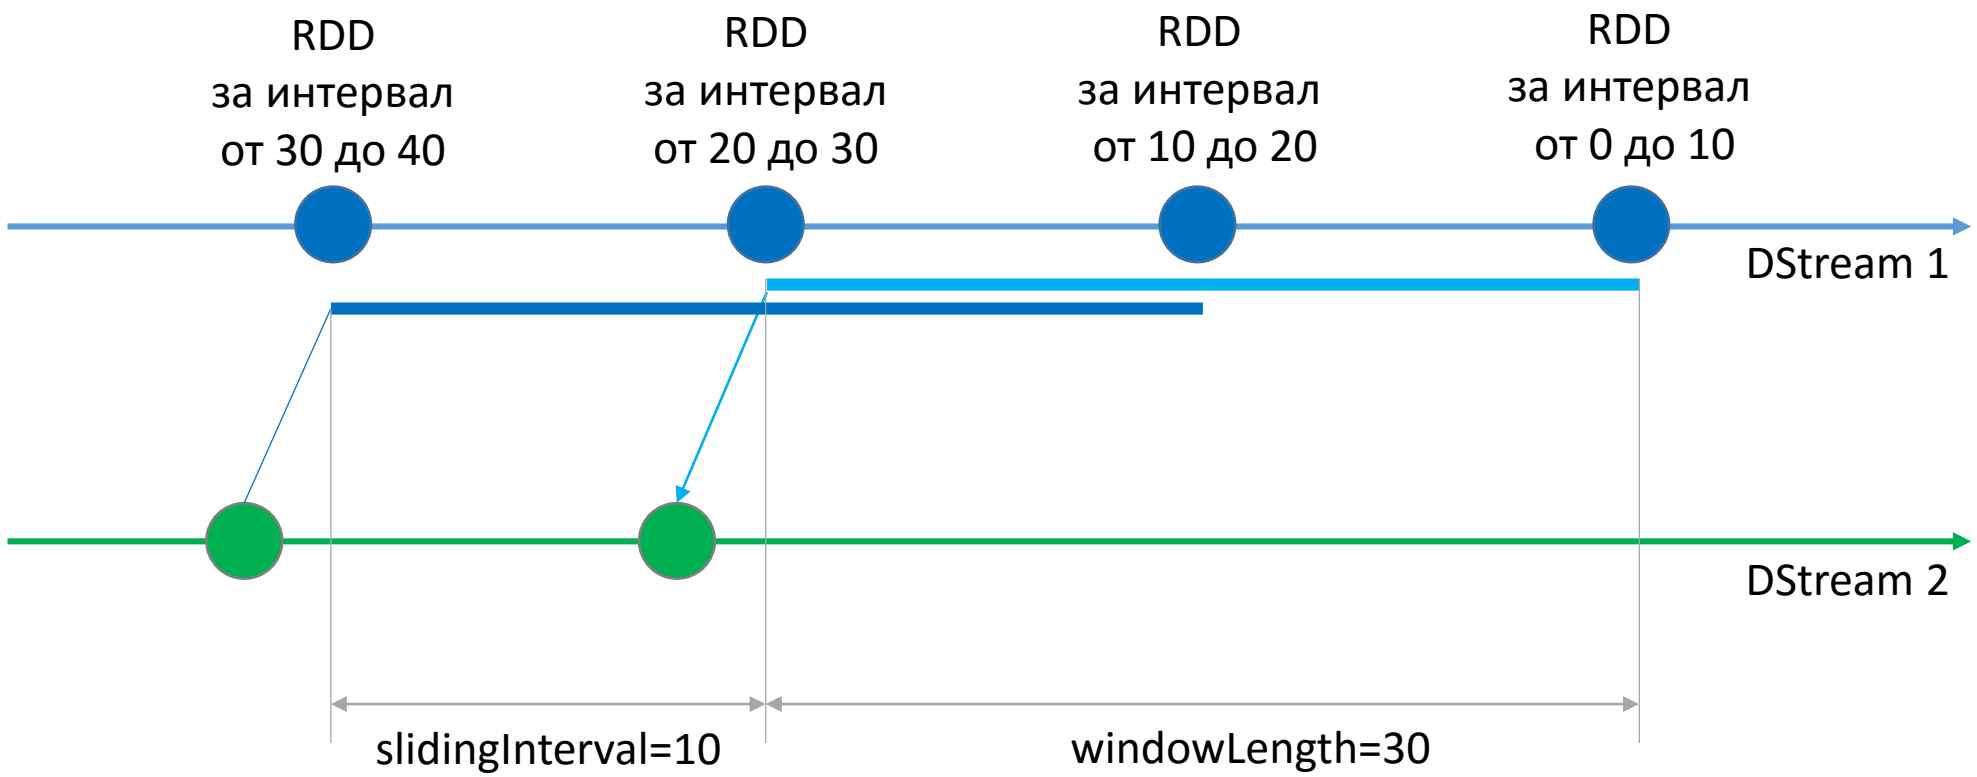

Трансформации с окном

window(windowLength, slideInterval)

countByWindow(windowLength, slideInterval)

reduceByWindow(func, windowLength, slideInterval)

reduceByKeyAndWindow(func, windowLength, slideInterval, [numTasks])

reduceByKeyAndWindow(func, invFunc, windowLength, slideInterval, [numTasks])

countByValueAndWindow(windowLength,slideInterval, [numTasks])

Трансформации reduceByWindow. Вариант 1

batchInterval=10

windowLength=30

slidingInterval=10

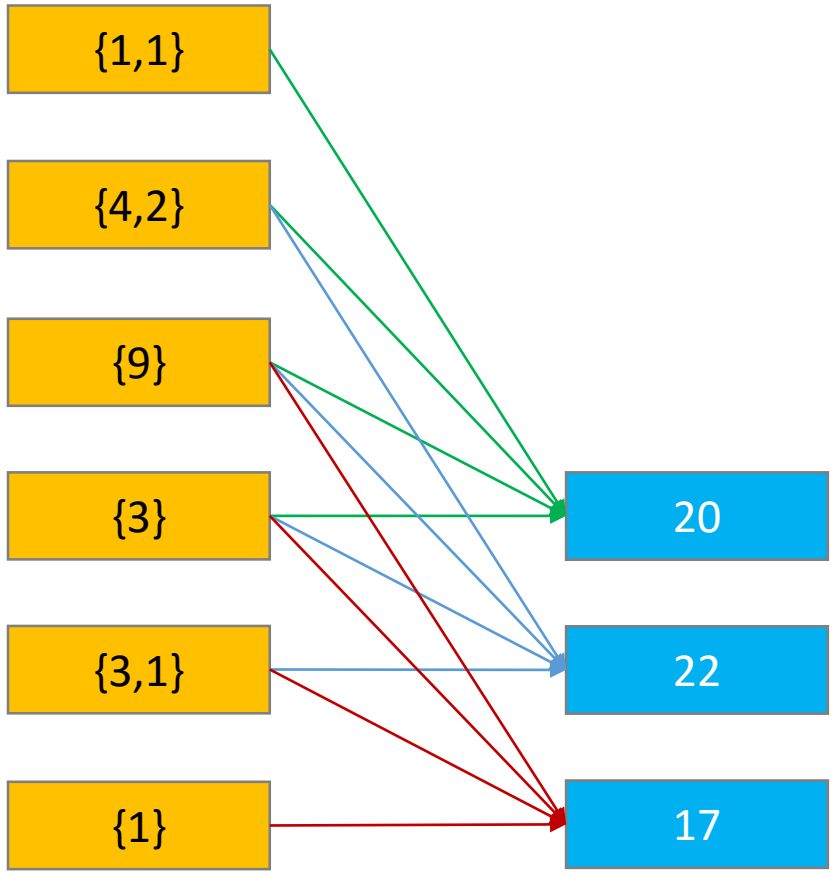

Трансформации reduceByWindow. Вариант 2

batchInterval=10

windowLength=30

slidingInterval=10

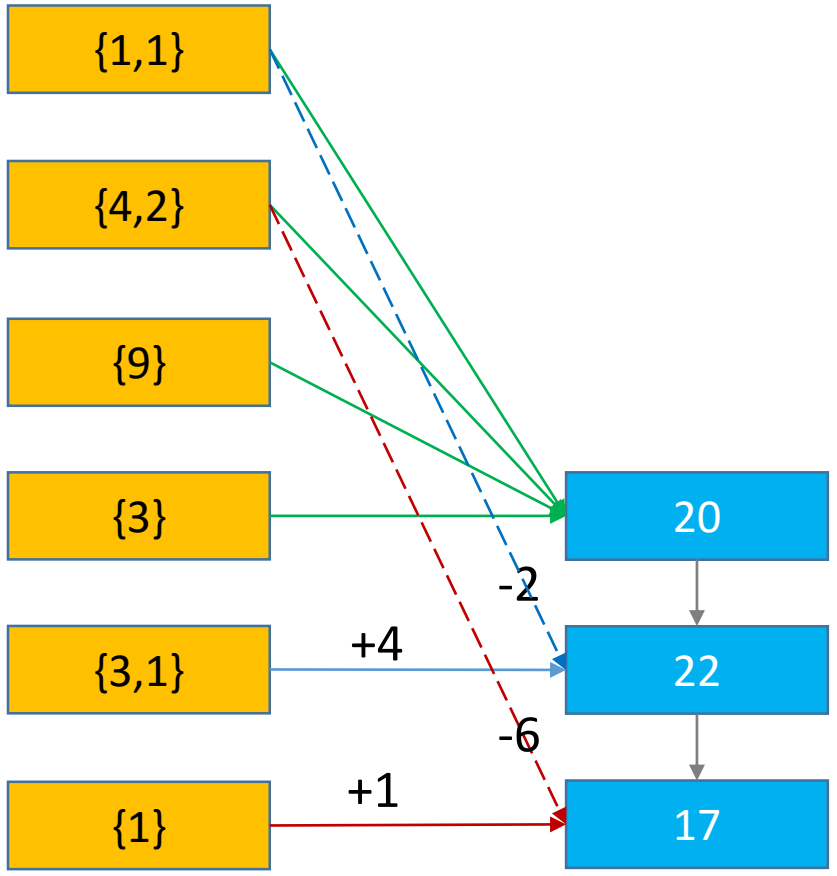

Действия. Output Operation

print()

saveAsTextFiles(prefix, [suffix])

saveAsObjectFiles(prefix, [suffix])

saveAsHadoopFiles(prefix, [suffix])

foreachRDD(func)

Архитектура Spark Streaming

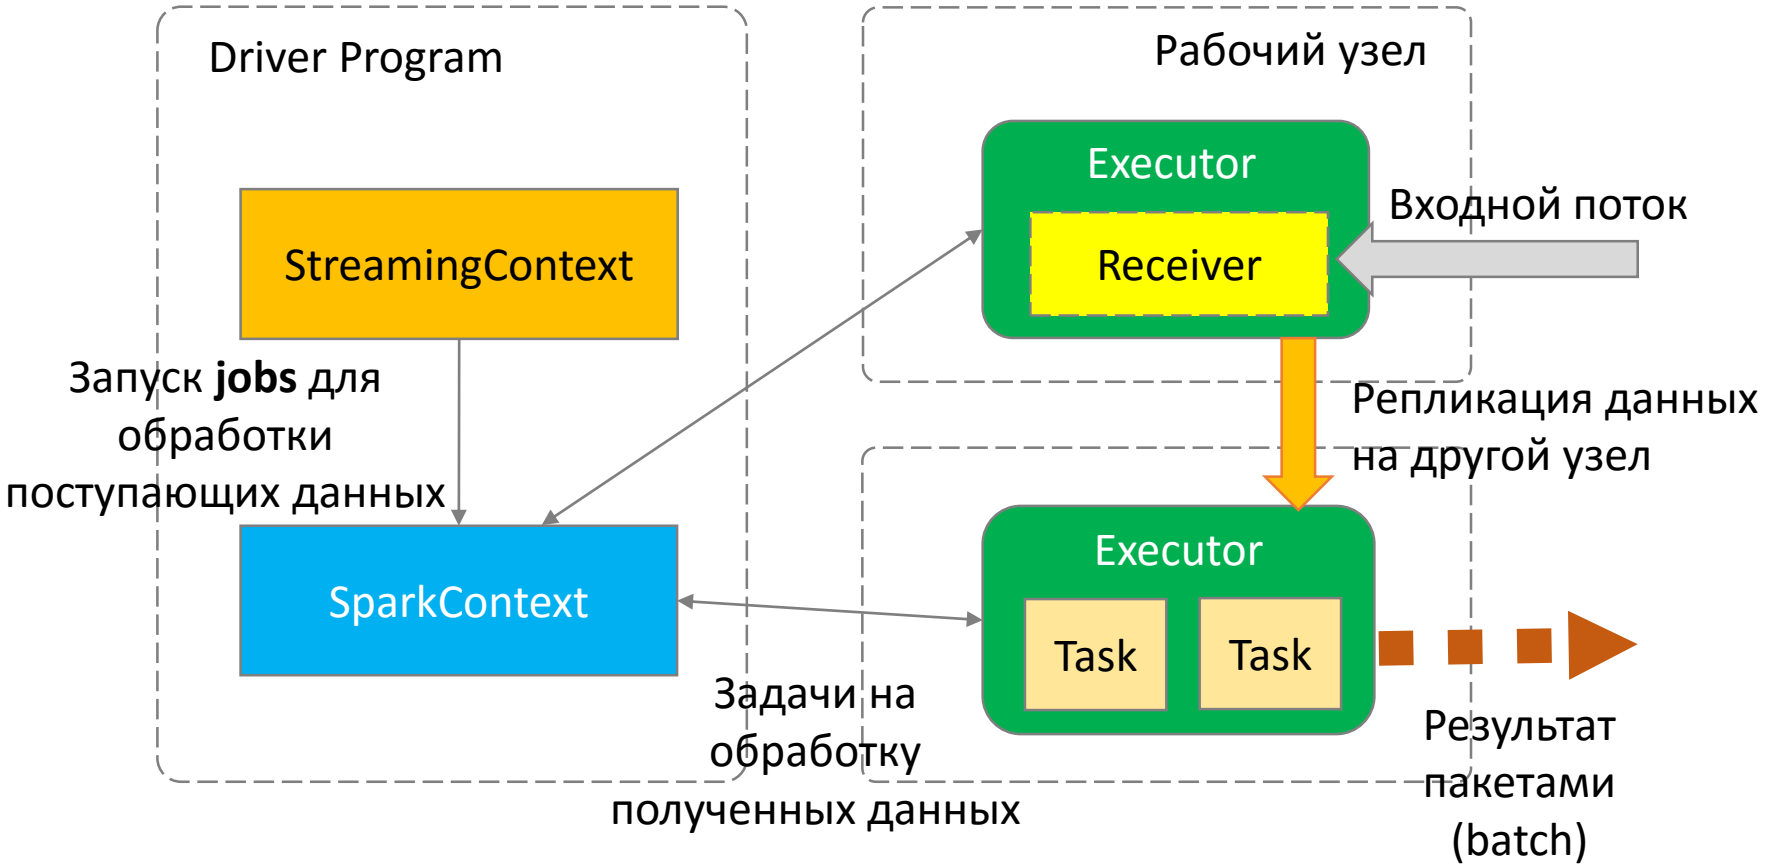

Особенности

- **DStream** соответствует одному **receiver**
- Для получения нескольких параллельных потоков (**DStream'**ов) необходимо несколько **receiver'**ов
- **Receiver** запускается на **executor'**е как задача
- Для работы **receiver'**а требуется одно ядро
- **Receiver'**ы назначаются **executor'**ам по Round-Robin манере

Особенности

- **Receiver** создает **блоки** данных по приему потока данных от источника
- Новый **блок** формируется в течение периода **blockInterval**
- **RDD** создается на **driver’**е для блоков сформированных в течение периода **batchInterval**
- В течение **batchInterval** создается **N** блоков $N = \text{batchInterval}/\text{blockInterval}$
- **Блоки** сгенерированные в течение **batchInterval** является **partition’**ами **RDD**
- **batchInterval** обычно от 0.5 до нескольких секунд

Особенности

- **BlockManager executor’**а отвечает за распределение **блоков** на другие **executor’**ы
- По умолчанию полученные данные копируются на два узла (две реплики)
- **Network Input Tracker** на **driver** информируется о расположении **блоков** для дальнейшей обработки
- Каждая **partition** соответствует задаче (**task**)
- Мар задачи (**task**) над **блоками** обрабатываются на **executor’**ах (на том, который получил блок от **receiver’**а, и на том, где реплика блока)

Особенности

- **JobScheduler** на **driver’**е планирует обработку RDD в виде работы (**job**)
- В каждый момент времени только одно **работа** активна
- Если одна **работа** выполняется, то другая – в очереди
- Если два потока **DStream**, то будет два RDD и две работы (**job**), которые будут запланированы последовательно (одна после другой)
- Чтобы избавиться от нескольких последовательных одинаковых **работ** для множества **DStream**, можно объединить потоки при этом это никак не повлияет на **partition’**ы RDD
- Если обработка входных данных (mini-batch) занимает больше времени чем **batchInterval**, то данные будут накапливаться на **executor’**ах, что может привести к переполнению и исключению

Отказоустойчивость

- Отказ **на рабочем узле**

  Все данные в памяти будут потеряны. Если на узле был receiver, то полученные данные в буфере также будут потеряны

- Отказ **узла driver'а**

  Spark Streaming приложение откажет, SparkContext будет утерян, и все executor'ы потеряют свои данные, хранящиеся в памяти (в оперативной – in-memory)

Отказоустойчивость. Отказ при получении данных

- Данные получены и **сформированы реплики** (две по умолчанию)

  В случае отказа узла будет копия на другом

- Данные получены, но **без реплик**

  Повторный запрос к источнику

Checkpoint

- **Checkpointing** в Spark Streaming – процесс периодического сохранения текущего состояния в надежном хранилище (например, HDFS)

- **Метаданные**

  для восстановления после отказа driver’а

- **Данные обработки** (RDD)

  для stateful трансформаций

Checkpoint. Метаданные

- **Конфигурация**

  Конфигурация, которая использовалась для создания приложения

- **DSteam операции**

  Множество **DStream** операций приложения

  Незавершенные пакеты (**batch**)

  Batch’и, которые в очереди работ (**job**)

Checkpoint. Данные

- Сохраняет созданные RDD в надежном хранилище
- Это необходимо для некоторых **stateful** трансформаций, которые комбинируют данные от нескольких **batch'**ей
- В таких трансформациях сгенерированная RDD зависит от RDD предыдущего пакета (**batch**)
- В свою очередь это ведет к увеличению последовательных зависимостей
- Чтобы избежать увеличения времени восстановления, промежуточные RDD периодически записываются в надежное хранилище (например, HDFS)
- Checkpoint каждые 5-10 batch'ей (рекомендация)

Гарантии

- Гарантии **получения** входных данных
- Гарантии в процессе **обработки** данных
- Гарантии **передачи** выходных данных (например, в систему хранения данных - СУБД, HDFS)

Гарантии получения входных данных

- Различные источники входных данных дают разные гарантии
- **Надежный receiver**:

  подтверждает надёжный источник только после репликации полученных данных. Если отказал receiver, то источник не получить подтверждение, и после перезапуска receiver’а, источник повторно отправит данные

- **Ненадежный receiver**:

  receiver не отправляет подтверждение и поэтому может потерять данные, когда выйдет из строя executor или driver

Гарантии в процессе обработки данных

- Все полученные данные обработаются гарантированно один раз (exactly once).
- Если произошел отказ, то до тех пор пока доступны исходные данные, может быть достигнут одинаковый конечный результат обработки (за счет отказоустойчивости при выполнении RDD)

Гарантии в процессе обработки данных

- Выходные операции по умолчанию обеспечивают семантику «at-least once» (по крайней мере один раз, но может и больше).
- Семантика зависит:
  - от типа выходной операции (идемпотентная или нет)
  - от семантики системы хранения (есть механизм транзакций или нет)

Источники

Learning Spark by H. Karau, A. Konwinski, P. Wendell, and M. Zaharia (book)

Spark Streaming Programming Guide (doc)